

Vibe vs Spec

같은 목표 페이지 , 추정 usage 비교

카페 랜딩 · 생성 산출물 2 개 · 표본 1 쌍

실제 청구 usage 나 무작위 배정된 SDD 실험이 아니다 .

카페 케이스 : 절감 관측의 증거 수준

usage 추정치 환산 -8.3%

고정 usage 추정치 + GPT-5 단가 : \$0.07135 → \$0.06540

토큰 합계 7,868 → 8,010 (+1.8%). 실제 청구 usage 가 아니라 세션 추정치다 .

캐시 적격성 미확인 . 모든 추정 입력을 신규 입력으로 환산하면 -8.1% .


Spec 은 Vibe 결과를 역산 . 백지 스펙 비용 · 재작업 감소 · 품질 동등성을 검증한 것은 아니다 .

두 산출물의 첫 화면


같은 목표, 다른 생성 과정

두 장 모두 실제 생성 HTML 을 Chromium 1280px 에서 캡처한 화면이다 .

보이는 화면이 비슷하다는 것이 품질 동등성의 증거는 아니다 .



위 : Vibe 산출물 첫 화면 (1280px)



아래 : Spec 산출물 첫 화면 (1280px)


demo/vibe_vs_spec/shots/vibe_top.png · demo/vibe_vs_spec/shots/spec_top.png

모바일 390px 에서도 같은 1 열

정적 문자열이 아니라 실제 렌더링

문자열 검사만으로는 2 열로 바뀌어도 통과한다 .

아래 그림은 현재 Spec 산출물을 390px 에서 캡처한 것이다 .




Spec 산출물 · 390×844 캡처

전체 페이지 길이 비교

세로로 긴 한 페이지, 두 산출물

원본 캡처 1,280×3,400 두 장을 같은 높이로 축소해 나란히 붙였다.

스크롤 길이가 비슷하다는 사실은 비용 · 품질 동등성 판정이 아니다.



왼쪽 Vibe 전체 페이지 · 오른쪽 Spec 전체 페이지 (축소)

demo/vibe_vs_spec/shots/vibe_full.png · demo/vibe_vs_spec/shots/spec_full.png · demo/vibe_vs_spec/make_fullpage_2up.py

입력이 늘고 비싼 출력이 줄었다

+666 / -680 / +156

이 케이스에서 input 과 cache 는 서로 겹치지 않는 버킷으로 정의했다 .

벤더 usage 필드 이름과 동일하다고 가정하면 이중 계상할 수 있다 .

비캐시 입력	486 → 1,152 (증가 666)
추론 + 보이는 출력	7,070 → 6,390 (감소 680)
캐시 입력 (추정)	312 → 468 (증가 156)
합계	7,868 → 8,010 (증가 1.8%)

세 단가로 같은 추정치를 환산

8.3% / 7.6% / 8.1% 비용 감소

토큰은 그대로 두고 단가와 캐시 가정만 바꾼 산술이다 .
다른 모델을 실행한 실측이 아니며 , 캐시 적격성은 미확인이다 .

GPT-5 · 캐시 \$0.125/M	\$0.0713465 → \$0.0653985 (8.3% 감소)
Claude Sonnet 4.6 · 캐시 0.1×	\$0.1076016 → \$0.0994464 (7.6% 감소)
GPT-5 · 캐시 전부 미적용	\$0.0716975 → \$0.0659250 (8.1% 감소)

단가비가 손익을 결정한다

$r > (666 + 156h) / 680$

r = 출력 / 입력 단가 , h = 캐시 읽기 / 입력 단가 .

모든 가격 체계에서의 보편 법칙이 아니라 고정 토큰 이동의 감도 분석이다 .

손익분기 조건	$r > (666 + 156h) / 680$
$h = 0.1$ 이면	$r = 1.0024$
$r \rightarrow \infty$ 수렴	약 9.62% 감소에 수렴
실제 청구서	미확인 (usage 추정치 산술)

품질 동등성 대신 실제 AC 범위를 공개

정적 16 항목 + 브라우저 29 항목

390/820/821/1280px 그리드 · 메뉴 표시 · 가로 스크롤 검사

각 카드의 내용과 세 앵커의 실제 스크롤 이동 검사

디자인 선호도 · 모든 사용자 의도 · 두 생성 과정의 품질 동등성은 검증하지 않는다 .

실패하는 반례도 넣는다

모바일 2 열 변조 → FAIL

CSS 에 미디어쿼리 문자열이 있다는 것만으로 1 열 전환이 보장되지 않는다 .

실제 렌더링된 `gridTemplateColumns` 를 확인한다 .

브라우저가 없으면 PASS 가 아니라 UNVERIFIED(exit 2).

반례의 비교 대상을 정확히 읽는다

SDD 도구 간 비교 ≠ SDD 대 무스펙

Spec-Kit +97~109%: OpenSpec 대비 두 사례의 외부 블로그 보고 . 둘 다 SDD 접근 .

ETH AGENTS.md 연구 : 저장소 컨텍스트 파일 조건 . 모든 짧은 스펙이 손해라는 실험 아님 .

짧고 필요한 요구사항만 쓰라는 실무 원칙은 유지하되 효과를 직접 측정한다 .

다음 실험 : 스펙이 재작업을 줄이는가

사전등록된 품질 · 비용 비교

백지 스펙 작성 비용부터 포함하고 다수 과제를 무작위 배정한다 .

같은 AC· 모델 · 출력 예산 · 가격 · 캐시 조건으로 성공률과 총비용을 기록한다 .

진행하지 않은 실험의 절감률은 결과로 채우지 않는다 .