

Vibe vs Spec

같은 목표 페이지 , 추정 usage 비교

카페 랜딩 · 생성 산출물 2 개 · 표본 1 쌍

실제 청구 usage 나 무작위 배정된 SDD 실험이 아니다 .

카페 케이스 : 절감 관측의 증거 수준

usage 추정치 환산 -8.3%

고정 usage 추정치 + GPT-5 단가 : \$0.07135 → \$0.06540

토큰 합계 7,868 → 8,010 (+1.8%). 실제 청구 usage 가 아니라 세션 추정치다 .

캐시 적격성 미확인 . 모든 추정 입력을 신규 입력으로 환산하면 -8.1% .

Spec 은 Vibe 결과를 역산 . 백지 스펙 비용 · 재작업 감소 · 품질 동등성을 검증한 것은 아니다 .

입력이 늘고 비싼 출력이 줄었다

+666 / -680 / +156

입력 +666, 추론 + 출력 -680, 캐시 +156 (추정값 고정)

이 케이스에서 input 과 cache 는 서로 겹치지 않는 버킷으로 정의했다 .

벤더 usage 필드 이름과 동일하다고 가정하면 이중 계상할 수 있다 .

단가비가 손익을 결정한다

$$r > (666 + 156h) / 680$$

r = 출력 / 입력 단가, h = 캐시 읽기 / 입력 단가

$h=0.1$ 이면 손익분기 $r=1.0024$. 모든 가격 체계에서의 보편 법칙은 아니다 .

다른 모델 단가에 고정 토큰을 대입한 감도 분석이지 다른 모델의 실호출이 아니다 .

품질 동등성 대신 실제 AC 범위를 공개

정적 16 항목 + 브라우저 29 항목

390/820/821/1280px 그리드 · 메뉴 표시 · 가로 스크롤 검사

각 카드의 내용과 세 앵커의 실제 스크롤 이동 검사

디자인 선호도 · 모든 사용자 의도 · 두 생성 과정의 품질 동등성은 검증하지 않는다 .

실패하는 반례도 넣는다

모바일 2 열 변조 → FAIL

CSS 에 미디어쿼리 문자열이 있다는 것만으로 1 열 전환이 보장되지 않는다 .

실제 렌더링된 `gridTemplateColumns` 를 확인한다 .

브라우저가 없으면 PASS 가 아니라 UNVERIFIED(exit 2).

반례의 비교 대상을 정확히 읽는다

SDD 도구 간 비교 $\neq$ SDD 대 무스펙

Spec-Kit +97~109%: OpenSpec 대비 두 사례의 외부 블로그 보고 . 둘 다 SDD 접근 .

ETH AGENTS.md 연구 : 저장소 컨텍스트 파일 조건 . 모든 짧은 스펙이 손해라는 실험 아님 .

짧고 필요한 요구사항만 쓰라는 실무 원칙은 유지하되 효과를 직접 측정한다 .

SDD 절감은 '턴 감소' 가정에 달린다

기존 71.0% / cold-cache 68.7%

40 턴 → 12 턴은 모델의 입력 가정 . 스펙이 실제 이만큼 줄었다는 관측은 없다 .

스펙 작성 : 입력 3,000 + 출력 4,000 비용을 이미 포함한다 .

기존 약 71% 는 캐시 예열 비용 제외 . 기본은 사이클별 첫 쓰기까지 포함한다 .

주장 유지 : 짧고 결정적인 스펙을 우선 시도하되 재작업 · 품질 · 총비용으로 검증한다 .

다음 실험 : 스펙이 재작업을 줄이는가

사전등록된 품질 · 비용 비교

백지 스펙 작성 비용부터 포함하고 다수 과제를 무작위 배정한다 .

같은 AC· 모델 · 출력 예산 · 가격 · 캐시 조건으로 성공률과 총비용을 기록한다 .

진행하지 않은 실험의 절감률은 결과로 채우지 않는다 .