

견적서의 나머지 항목

조건을 명시하는 비용 절감

캐시 · 루프 · 스펙 · 서브에이전트 · 정책 재생

모든 숫자에는 실측 / 가정의 구분이 붙는다 .

요금은 모델 ID 와 단가를 함께 본다

\$0.25 / \$1.50

Gemini 3.1 Flash-Lite · Standard text · USD / 1M tokens

출력에는 `thoughtsTokenCount` + `candidatesTokenCount` 를 포함한다 .

기존 \$1.25/\$10 은 발표 환산 가정으로 보존한다 . Flash-Lite 공식 과거 가격이라는 뜻은 아니다 .

$\text{usage} \times \text{리스트 단가}$ 는 청구서가 아니다 . 무료 티어 · 계약 · 세금 · 도구료는 별도 .

압축과 캐싱은 대체재만이 아니다

\$0.4014 → \$0.2007

Sonnet 단가, 프리픽스 12,000, 100 회: 첫 쓰기 + 이후 99 회 캐시 읽기.

원문 캐시 \$0.4014 / 절반 압축 + 캐시 \$0.2007.

압축 비용 · 품질 · 최소 길이 · TTL 조건을 만족해야 한다. 요약 생성 비용은 이 표 밖이다.

캐시 적격성은 모델별로 다르다

Haiku 4.5: 최소 4,096 토큰

Sonnet 4.6: 1,024 / Opus 4.6: 4,096 (공식 문서 확인일 2026-09-20)

짧은 프리픽스를 1K 공통 규칙으로 할인하지 않는다 . 미확인 기준은 ‘미확인’으로 둔다 .

적격성 충족은 히트 보장이 아니다 . 실제 cache usage·TTL·쓰기 / 저장료를 본다 .

캐싱의 손익은 조건으로 재현한다

기본 시나리오 62.35% 절감

고정 20,000 + 가변 1,000, 출력 1,500, 100 회, Sonnet: \$8.550 → \$3.219

히트 0, 매번 쓰기 가정은 \$10.050. 캐시 없음보다 비쌀 수 있다.

‘캐싱 90%’는 캐시 읽기 단가 할인이다. 전체 세션 절감률과 다르다.

SDD 절감은 '턴 감소' 가정에 달린다

기존 71.0% / cold-cache 68.7%

40 턴 → 12 턴은 모델의 입력 가정 . 스펙이 실제 이만큼 줄었다는 관측은 없다 .

스펙 작성 : 입력 3,000 + 출력 4,000 비용을 이미 포함한다 .

기존 약 71% 는 캐시 예열 비용 제외 . 기본은 사이클별 첫 쓰기까지 포함한다 .

주장 유지 : 짧고 결정적인 스펙을 우선 시도하되 재작업 · 품질 · 총비용으로 검증한다 .

절감률을 쌓을 때도 가정을 드러낸다

85.825%

잔여비용에 30%, 40%, 50%, 25%, 10% 를 순차 적용한 산술 결과 .

85.825% 는 60-80% 범위 밖이다 . ‘일치한다’는 표현은 삭제한다 .

레버의 중복 · 상호작용 · 추가 비용을 검증하지 않았다 . 경험적 상한도 아니다 .

서브에이전트는 전체 비용으로 비교한다

메인 + 자식 + 요약 비용

동일 톨 작업 가정 : naive \$5.6010, compact \$3.4425, subagent \$2.7360

20 턴 , 매 턴 톨 8,000, 초기 5,000, 출력 300, 요약 1,500, 같은 Sonnet 단가 .

기존 -87% 는 자식 · 요약 비용이 빠진 메인 컨텍스트 계산이었다 .

동일 작업량 가정이어도 요약 품질 · 실패 · 재시도까지 같다고 검증한 것은 아니다 .

사다리 재생은 정책 A/B 실측이 아니다

리플레이는 유용하다 . 명칭을 바꾼다 .

기존 3.06 배는 고정 발화를 다른 정책으로 처리한다는 비용 재생이었다 .

지금은 respec 의 무료 중단과 실행 비용을 분리하고 , 총 입력 증가분을 한 번만 더한다 .

A· 오케스트레이터는 범위 · 리셋 · 출력 상한 · 진단 후 적용 비용을 공통 함수로 계산 .

새 task_id 의 의도 이력을 분리해 앞 작업의 재작업 상태가 새 작업으로 새지 않게 한다 .

숫자를 직접 확인할 수 있게 남긴다

원자료 · 산식 · 기준일 · 재현 명령

results/audit_metrics.json: 저장 로그 통계 + 로컬 측정 + 시나리오를 분리한 지표 .

docs/CORRECTIONS.md: 무엇을 유지하고 무엇을 바꿨는지 상세 설명 .

SOURCES.md: 공식 단가 , 논문 표 , 외부 케이스의 비교 조건 .

원본 110 행은 보존 . 없는 원자료를 재측정 없이 만들어 넣지 않는다 .