

FOLLOW-UP · 에이전트 셋팅편

작은 모델이 지휘한다

비싼 모델을 기본값에서 끌어내리는 법

라우터 · 웹세션 위임 · 3 줄 설명 · 배치 · 세션 리셋 — 실제 도는 코드로

앞의 두 덩어리는 “요금을 어떻게 읽는가”였다. 이번엔 그 원칙을 매 요청마다 자동으로 적용하는 배선을 짤다.

이 덩어리의 모든 슬라이드는 `agent_setup/` 에 대응 코드가 있고, IDE 에 바로 붙습니다. 검증 181 건 전부 PASS — 라우터 98 · 프로토콜 61 · 공식 SDK 22.

기본값이 비싸다

대부분의 팀은 "가장 좋은 모델 하나"를 골라 모든 요청에 쓴다. 파일 이름 바꾸기도, 아키텍처 설계도 같은 창구로 간다.

요청	실제 필요한 능력	지금 (기본값)	있어야 할 배선
파일 rename · grep	틀 호출	상위 모델	소형 / 코드
결정된 스펙 구현	코드 생성	상위 모델	중간 모델
방금 짰 코드 설명	설명	상위 모델 · 20 줄	소형 · 3 줄
아키텍처 트레이드오프	추론	상위 모델 · 사고 ON	웹 세션 위임
40 개 사이트 정규화	대량	상위 모델 · 동기	배치 - 50%

요청의 종류를 판정하는 데 드는 비용은 수십 토큰이다. 상위 모델 호출 한 번만 막아도 즉시 회수된다.

당신이 만든 것은 무엇인가

" 이게 라우팅인가 리워크 플로우인가 " — 셋은 층위가 다르다 . 섞어 부르면 처방도 섞인다 .

① 라우팅

요청 1 건을 어느 모델로 보낼지 고른다 .

대상 : 단가 (모델 선택)

효과 : -49~84 % (exp06)

단위 : 요청 하나

② 리워크

틀려서 되돌아온 일을 다시 시킨다 .

대상 : 횟수 (턴 반복)

효과 : 48 턴 = 16.6 배 (exp09-C)

단위 : 턴의 누적

③ 워크플로우 컨트롤

파이프라인 전체를 지휘한다 . ①② 를 품는다 .

대상 : 구조 (무엇을 · 어디서 · 몇 번)

효과 : 위 둘의 곱

단위 : 세션 전체

답 : 당신이 설계한 것은 ③ 워크플로우 컨트롤이다 .

라우팅은 그 안의 한 수단이고 , 리워크는 그 컨트롤이 줄이려는 대상이다 . " 리워크 플로우 " 는 되돌아온 작업을 처리하는 흐름을 뜻하므로 목표가 아니라 실패 경로다 .

전체 배선도

작은 모델 (또는 정규식) 이 문 앞에 서서 분류한다 . 그 판정 하나로 이후 비용이 결정된다 .



agent_setup/router.py — route() 한 함수가 위 분기 전부를 담는다 . 의존성 없음 , 오프라인 동작 .

라우터 — 실제 코드

규칙이 먼저다. 정규식으로 잡히면 분류 비용이 0 원이다. 못 잡을 때만 소형 모델을 부른다.

```
RULES = [ # 순서가 곧 우선순위
    (Kind.TOOL,      r" 파일 | 경로 | grep | 검색해 | 커밋 "),
    (Kind.BULK,      r" 일괄 | 정규화 | 라벨링 | \d{2,}( 개 | 건 )"),
    (Kind.REASONING, r" 설계 | 아키텍처 | 트레이드오프 "),
    (Kind.EXPLAIN,   r" 설명 | 무슨 뜻 | 어떻게 동작 "),
    (Kind.IMPLEMENT, r" 구현 | 만들어 | 고쳐 | 리팩터 | 버그 "),
]

def route(task, small_llm=None, *,
         allow_external=True):
    kind, by = classify(task, small_llm)
    if kind is Kind.REASONING and allow_external:
        return Decision(kind, Tier.EXTERNAL,
                        {"mode": "web-chat"})
    if kind is Kind.IMPLEMENT:
        return Decision(kind, Tier.MID,
                        {"explain": "3-lines",
                         "max_out_tok": 2500})
```

왜 규칙이 먼저인가

분류에 LLM 을 쓰면 그 자체가 요청당 비용이다.

한국어 업무 요청 대다수는 동사 몇 개로 갈린다.

규칙 미스는 소형 모델이 받는다 — 2 단 방어.

순서가 정확도를 만든다

한국어 업무 요청 10 종 : 10/10 일치.

"TODO 전부 grep" 은 BULK 가 아니라 TOOL 이다.

겹치는 규칙은 좁은 쪽을 위로 올릴 것.

규칙 기반 라우터의 버그는 대부분 순서 문제다. 규칙을 추가할 때마다 분류 테스트 98 건을 다시 돌린다.

추론은 정액제 창구로 — 그리고 그 대가

긴 추론은 종량 과금에서 가장 비싼 항목이다. 이미 결제 중인 웹 세션에서 끝내고 결론만 주입하면 그 항목이 0 이 된다.

방법 — 로그인된 세션 재사용

- 1. Playwright 로 사용자 프로필 디렉터리를 열어 기존 로그인 쿠키를 그대로 쓴다.
- 2. 문제 정의를 붙여넣고 응답이 끝날 때까지 대기한다.
- 3. 결론을 spec.md 로 저장 → 중간 모델에 입력으로 주입.

효과 : 사고 토큰 과금 0. 앞 덱 실측에서 사고 자동 설정은 240 배였다.

리스크 — 약관을 먼저 읽어라

OpenAI · Google 모두 이용약관에서 자동화된 수단으로의 서비스 접근 · 스크래핑을 제한한다. 계정 정지 사유가 될 수 있다.
업무 데이터를 개인 계정 웹 세션에 넣는 것은 별도의 보안 · 컴플라이언스 문제다.
조직 자산에 이 경로를 넣기 전에 법무 · 보안 확인을 받을 것.

같은 효과를 내는 합법적 대안 — 이쪽을 기본값으로

경로	이점	비용 / 제약	권고
사람이 직접 웹에서 추론	약관 문제 없음	수동 복붙 1 회	권장
API + effort 제한	완전 합법 · 자동화	사고 토큰 일부 과금	권장
Batch API 로 추론 위임	단가 - 50%	지연 최대 24h	조건부
Playwright 자동 조작	종량 0 원	약관 위반 소지 · 정지 위험	비권장

이 슬라이드는 " 하지 말라 " 가 아니라 " 알고 고르라 " 는 뜻이다. 개인 실험과 조직 배포의 기준은 다르다.

구현은 중간 모델로 내려도 되나

스펙이 정해진 구현은 상위 모델을 덜 탄다. 다만 무조건은 아니다.

이렇게 내리면 사고가 난다 (X)

"스펙만 정해졌으면 아무 모델이나 된다"

내려도 되는 기준 (O)

세 조건이 동시에 만족될 때 격차가 좁혀지거나 역전된다

■ ① 스펙이 확정됐을 때

요구사항 분류 과제에서 8B와 상위 모델의 F1 격차는 평균 0.02. 판단이 끝난 일은 크기를 덜 탄다.

■ ② 출력 검증 수단이 있을 때

단위 테스트로 후보를 거를 수 있으면, 고정 컴퓨트 예산에서 7~13B가 34~70B를 최대 15% 상회한다.

■ ③ 임계 크기 이상일 때

3B 미만은 유의하게 떨어진다. 단 Qwen2.5-Coder 1.5B처럼 7B 급을 이기는 반례도 있다 — 크기보다 학습 품질.

반대 방향 근거 — pass@1을 10% 올리려면 VRAM 약 4배가 필요하고, Rosetta Code 번역에서는 파라미터 수에 따라 성능이 계속 스케일한다. 스펙이 모호하거나 다단계 추론이 필요하면 격차는 그대로 남는다.

배치 — 단가는 반값, 시간은 약속이 아니다

반값은 사실이다. 문제는 언제 끝나는지를 아무도 약속하지 않는다는 것이다.

벤더	할인	공식 창구	주의
OpenAI Batch	-50%	24 시간 내 완료	미완 시 expired
Google Gemini	-50%	SLO 24 시간	대형 잡은 분할 권장
xAI	-50%	대부분 24 시간 내	best effort
Anthropic	-50%	24 시간 내	대부분 1 시간 내 종료

실제로 깨진 사례

2025년 2월, 기존 1~2 시간에 끝나던 잡이 24 시간에 근접.
 expire 비율이 0% 에서 25% 이상으로 악화된 사례 다수 보고.
 대응: 배치 크기를 절반으로 줄이거나 모델 버전을 고정.

그래서 배치는 세 조건을 모두 만족할 때만 쓴다

- ① 턴 간 의존이 없을 것
에이전트형 다단계 작업은 매 턴 배치 대기가 누적돼 수 시간 ~ 수일이 된다. 부적합.
- ② 마감일 없을 것
자료조사 · 분류 · 정규화 · 임베딩처럼 사람이 기다리지 않는 일.
- ③ **expire** 재시도 경로를 설계할 것
"N 시간 내 미완이면 동기 처리로 전환" 을 코드에 넣는다 — `fallback: sync-after-2h`.

출력을 막는 두 개의 밸브

프롬프트로 "짧게 답해" 라고 부탁하는 것은 지켜지지 않는다. 코드로 잘라야 지켜진다.

밸브 1 — 설명 3줄 상한

```
def explain_guard(text, max_lines=3):  
    lines = [ 비어있지 않은 줄들 ]  
    if len(lines) <= max_lines: return 그대로  
    return 앞 3 줄 + "(+N 줄 생략 — '자세히' 로 재요청)"
```

구현 직후의 관성적 설명은 소형 모델 + 3 줄. "자세히 / 깊게 / 문서로" 가 있을 때만 full.

밸브 2 — 세션 위생 (리셋은 마지막 수단)

같은 설명이 반복되면 → 컴팩션. 세션은 살려두고 결론만 남긴다.
리셋은 완료된 결과가 원하던 방향이 아닐 때만 건다.
검증 실패는 방향 문제가 아니다 → 리셋 말고 리워크.
반복을 곧바로 리셋으로 처리하면 아직 쓸모 있는 맥락까지 버린다.

-83%

장황 342tok → 간결 58tok (exp05)

3 회

동일 설명 반복 시 컴팩션 (리셋 아님)

16.6 배

48 턴 리워크의 비용 (exp09-C)

재생성한 출력은 다시 입력이 되어 이후 모든 턴의 단가를 올린다. 그렇다고 세션을 통째로 버리면 맥락 재장전 비용을 또 묻다 — 그래서 컴팩션이 먼저다.

실패하면 — 칸은 세 개면 된다

라우팅은 첫 배정만 정한다. 돈이 실제로 타는 곳은 실패하고 다시 시작하는 구간이다.

흔한 실패 (X)

첫 실패에 곧바로 모델을 올린다. 칸을 잘게 쪼갤수록 안전해 보이지만 비싸지기만 한다.

해야 할 일 (O)

범위를 넓히고 → 안 되면 세션을 끊고 → 안 되면 스펙으로 돌아간다. 세 칸.

칸	이름	티어	다시 여는 범위	세션	이 칸이 하는 일
1	widen	MID	파일 전체 + 호출부	유지	모델은 그대로 둔다
2	reset	MID	확정된 것만 이월	새 세션	입력 누적을 끊는다
3	respec	중단	스펙으로 복귀	새 세션	구현을 더 시키지 않는다

모델을 올리는 칸은 상시로 두지 않는다 — 조건부다

의도가 어긋나는 이유는 다섯 가지 (범위 · 취향 · 전체 · 판단오류 · 맥락오염) 인데, 모델을 올려서 풀리는 건 그중 하나뿐이다. 분류기가 그 하나로 판정할 때만 칸을 끼운다.

칸을 일곱에서 셋으로 줄였더니 같은 대화 기록에서 \$0.3574 → \$0.1170 — 3.06 배 싸졌다.

세션 리셋은 실패 횟수가 아니라 방향이 어긋났을 때 건다 — 검증 실패는 결함이고, 결함은 같은 맥락 안에서 고치는 편이 싸다.

사다리는 비싸질까 — 숫자로

" 단계를 밟다 보면 비용이 폭발하지 않나 " — 정당한 우려다 . 측정해서 답한다 .

실패 횟수	제자리 재시도	사다리	사다리가 싼 배수
0 회 (성공)	\$0.0272	\$0.0272	동일
1 회	\$0.0625	\$0.0465	1.34 배
2 회	\$0.1073	\$0.0591	1.81 배
3 회	\$0.1611	\$0.1141	1.41 배
4 회	\$0.2239	\$0.1141	1.96 배
6 회	\$0.3764	\$0.1141	3.30 배
10 회	\$0.7895	\$0.1141	6.92 배

① 짧아도 이득이다

1 회 26% · 2 회 45% 절감 .

② 상한이 걸린다

3 칸에서 멈춰 \$0.1141 에서 정지 .

③ 사다리가 싼 이유는 좋은 모델을 써서가 아니다 — 입력이 안 불어나서다

제자리에서 다시 시키면 그때까지의 대화가 통째로 입력에 다시 실린다 . 실측하면 턴마다 4,700 토큰씩 불어난다 .

이 누적을 빼고 계산하면 6 회 실패 제자리 \$0.1874 → 실제로는 \$0.3764 . 절반으로 과소평가하게 된다 .

리셋 칸은 이 누적을 0 으로 끊는다 . 사다리의 이득은 거기서 나온다 .

그럼 두 칸으로 줄이면 더 싸지나

줄여서 싸졌으니 더 줄이면 더 싸질 것 같다. 그 방향으로 끝까지 밀어보면 어디서 깨지는지 나온다.

모델을 올려야만 풀리는 일이 실제로 있다

모델 올리는 칸을 아예 없애면, 그런 일은 세 칸을 다 쓰고도 못 풀고 사람에게 넘어간다. 토큰은 아꼈는데 사람 시간을 쓴다.

설정	경로	토큰	사람 시간	실질 비용
조건부 칸 있음	widen → 모델 ↑ — 해결	\$0.1377	—	\$0.1377
없앤 경우	widen → reset → respec — 사람 호출	\$0.0832	\$0.10	\$0.1832 (1.3×)
			\$0.50	\$0.5832 (4.2×)
			\$2.00	\$2.0832 (15.1×)

그래서 지우지 않고 조건부로 둔다

상시 칸에서는 빠되, 분류기가 난이도 문제로 판정할 때만 한 칸 끼운다.

사람 시간은 가정값이다

\$0.10 / \$0.50 / \$2.00 세 가지로 벌려 놓았다. 어느 값을 넣어도 결론은 뒤집히지 않는다.

줄이는 게 목적이 아니라 값을 하는 칸만 남기는 게 목적이다 — 값을 하는 칸까지 지우면 비용은 다른 데로 옮겨갈 뿐이다.

라이브 — 지금 돌려봅니다

python3 agent_setup/test_router.py — 의존성 없음 . 인터넷 없어도 됩니다 .

[1] 분류 정확도

PASS 결제 모듈 아키텍처 설계 트레이드오프 정리해줘 → reasoning
PASS 스펙대로 핸들러 구현해줘 → implement
PASS 방금 짠 코드 설명해줘 → explain
PASS src 밑에서 TODO 전부 grep 해줘 → tool
PASS 경쟁사 40 개 가격 페이지 조사해서 정규화해줘 → bulk

[2] 라우팅 티어 [3] 설명 3 줄 강제
[4] 세션 리셋 트리거 [5] 비용 산식
[6] 리워크 에스컬레이션 [7] 손익분기

전부 LARGE \$0.4845 → 라우팅 \$0.0559 (88.5% 절감)
사다리 3 턴 \$0.0519 = 제자리 2 턴 \$0.0545

98 건 중 98 PASS / 0 FAIL

시연 순서

1. router.py — 5 개 요청의 행선지
2. 같은 작업을 3 번 실패시켜 사다리 관찰
3. IDE 에서 같은 판단이 나오는지 확인

숫자를 읽는 법

88.5% 는 " 전부 상위 모델 " 대비 추정치다 .
실제 절감폭은 요청 구성비에 따라 달라진다 .
PRICES 상수를 각자 단가로 바꿔 다시 재라 .

agent_setup/router.py (라우터) · test_router.py (98 건) · mcp_server.py + test_mcp.py (61 건) — 저장소에 그대로 들어 있습니다 .

실제 IDE 에 붙이기 — MCP

지금까지는 라이브러리였습니다 . 에이전트가 스스로 부르게 하려면 배선이 필요합니다 .

왜 MCP 인가

Antigravity 가 외부 로직을 받아들이는 표면은 MCP 하나다 .
 모델 선택을 가로채는 혹은 공개돼 있지 않다 .
 그래서 라우터를 " 도구 " 로 노출해 에이전트가 묻게 만든다 .

```
// < 프로젝트 >/.agents/mcp_config.json
{ "mcpServers": {
  "token-router": {
    "command": "python3",
    "args": ["/abs/path/mcp_server.py"]
  }
} }
```

API 키가 필요 없다

이 서버는 모델을 호출하지 않는다 . 판단만 돌려준다 .
 어디로 보낼지 · 몇 토큰까지 쓸지 · 지금 리셋할지 .
 실제 호출은 이미 구독 중인 에이전트가 한다 .

위치	경로	비고
전역 (2.0)	~/.gemini/config/	권장
워크스페이스	< 프로젝트 >/.agents/	팀 공유
레거시 1.x	~/.gemini/antigravity/	조용히 무시됨

원격 서버는 키가 serverUrl 이다 .

url · httpUrl 은 안 먹는다 . 다른 IDE 예제를 그대로 붙이면 여기서 막힌다 .

python3 agent_setup/install_antigravity.py — 설정 파일을 찾아 병합해 등록합니다 . 기존 서버는 보존 , 재실행해도 안전 . 저장 후 에디터 재시작 .

붙이면 무엇이 달라지나

에이전트가 매 작업마다 라우터에게 먼저 묻고 , 그 답을 지킵니다 .

언제	도구	무슨 답이 오나	역할
작업 시작	route_task	어느 티어로 · 출력 몇 토큰까지	배정
실패했을 때	rework_next	사다리에서 다음 한 칸만	에스컬레이션
매 턴 끝	session_check	continue / compact / reset	세션 위생
설명할 때	trim_explain	요청 없으면 3 줄로 자름	출력 상한
회고	cost_report	무엇을 아꼈는지 집계	측정

" 규격에 맞다 " 고 말하려면 남의 구현이 붙어야 한다

- 1 층 자체 프로토콜 왕복

61/61
- 2 층 공식 MCP SDK 클라이언트

22/22
- 3 층 공식 Inspector (IDE 경로)

도구 5 개 인식
- 4 층 설정 파일에서 출발한 연결

연결 · 호출 확인

디버깅은 각오할 것

연결 실패가 UI 에 안 뜬다 . 로그는 stderr.

bash agent_setup/verify_all.sh — 네 층위를 한 번에 돌립니다 . AGENTS.md 를 워크스페이스에 두면 도구 호출 시점까지 강제됩니다 .

내일부터 뭘 커나

전부 한 번에 커지 않는다 . 위험이 낮고 효과가 즉시 보이는 것부터 .

시점	무엇을	어떻게	기대 효과	주의
1 일차	설명 3 줄 상한	프롬프트 + 후처리 컷	즉시 - 40~60% 출력	없음
1 주차	규칙 기반 라우팅	route() 붙이고 로그만 남김	측정 먼저	오분류
2 주차	라우팅 실제 적용	툴 · 설명부터 소형으로	-49~84%	품질 회귀
3 주차	세션 리셋 자동화	반복 감지 → 커밋 → 재시작	컨텍스트 단가 억제	맥락 유실
4 주차	배치 도입	마감 없는 대량 작업만	-50%	expired
보류	웹 세션 자동 조작	법무 확인 전까지 수동	총량 0 원	약관

측정 없이 커지 마라 .

1 주차에 로그만 남기는 이유가 이것이다 . 라우팅 전후의 요청당 비용과 리워크 턴 수를 같이 재야 , 절감이 진짜인지 품질을 팔아 산 것인지 구분된다 .

되돌릴 수 있게 만들어라 — route() 가 항상 상위 모델을 반환하도록 하는 킬 스위치 하나면 롤백이 끝난다 .

정리

- **작은 모델은 답을 만드는 게 아니라 교통을 정리한다**
분류에 드는 수십 토큰이 상위 모델 호출 하나를 막으면 즉시 회수된다.
- **당신이 만든 것은 워크플로우 컨트롤이다**
라우팅은 그 안의 수단이고, 리워크는 그것이 줄이려는 대상이다.
- **구현 티어는 조건을 확인하고 내린다**
스펙 확정 · 검증 수단 · 임계 크기 — 셋이 모일 때만 중간 모델로 내려도 안전하다.
- **배치는 단가를 반으로 줄이지만 시간은 약속하지 않는다**
expired 가 실제로 난다. 폴백 없는 배치는 파이프라인을 멈춘다.
- **밸브는 프롬프트가 아니라 코드로 잠근다**
3 줄 상한과 세션 리셋은 부탁이 아니라 후처리로 강제해야 지켜진다.

세 텍스트를 관통하는 한 문장 — AI가 나쁜 게 아니라 우리가 견적서를 안 읽은 것이다.

Q & A

코드는 전부 저장소에 있습니다

agent_setup/router.py — 라우터 · 3 줄 밸브 · 세션 메모리 · 비용 추정

agent_setup/mcp_server.py — 이 라우터를 MCP 도구 5 개로 노출 (의존성 0)

test_router.py 98 건 · test_mcp.py 61 건 — 전부 PASS

presentation/deckgen/ — 이 덱들을 만든 빌드 스크립트 전부

PRICES 상수만 각자 단가로 바꾸면 자기 팀 숫자가 나옵니다.

가져가실 것 하나만 고르라면 — 설명 3 줄 상한 .

오늘 오후에 켤 수 있고 , 되돌리는 데 1 분 걸립니다 .



github.com/giyeop-cody/token-cost-lab